UTS Sistem Cerdas

Nama: Muhammad Aldi Almi NIM: 2411002 Kelas: Informatika 24

SOAL 1 — Studi Kasus Terpadu (FIS · Sistem Pakar · XGBoost)

1a. Fuzzy Inference System (FIS) Mamdani

Rancangan: 2 input (Z-Score BB/U dan Z-Score TB/U, range −4 s.d. +3) dan 1 output (Skor Risiko Stunting 0–100). Metode: Mamdani, AND = min, implikasi = potong (clip), agregasi = max, defuzzifikasi = centroid.

(i) Fungsi Keanggotaan

Rumus segitiga (a,b,c): naik (x−a)/(b−a), turun (c−x)/(c−b). Trapesium (a,b,c,d): naik (x−a)/(b−a), datar 1 di b–c, turun (d−x)/(d−c).

Variabel	Himpunan Fuzzy	Tipe	Parameter
Z-Score BB/U (−4 s.d. 3)	RENDAH (< −2)	Trapesium (bahu kiri)	a = −4, b = −4, c = −3, d = −1
	NORMAL (−2 s.d. 2)	Segitiga	a = −3, b = 0, c = 3
	TINGGI (> 2)	Trapesium (bahu kanan)	a = 1, b = 2, c = 3, d = 3
Z-Score TB/U (−4 s.d. 3)	PENDEK (< −2)	Trapesium (bahu kiri)	a = −4, b = −4, c = −3, d = −1
	NORMAL (−2 s.d. 2)	Segitiga	a = −3, b = 0, c = 3
	TINGGI (> 2)	Trapesium (bahu kanan)	a = 1, b = 2, c = 3, d = 3
Skor Risiko (0–100)	RENDAH (0–30)	Segitiga	a = 0, b = 15, c = 30
	SEDANG (25–65)	Segitiga	a = 25, b = 45, c = 65
	TINGGI (60–100)	Segitiga	a = 60, b = 80, c = 100

Catatan desain: pada z = −2, RENDAH = 0,5 dan NORMAL = 0,33, artinya nilai z = −2 adalah batas klinis yang "abu-abu" — itulah alasan memakai logika fuzzy, bukan batas tegas.

(ii) Rule Base (9 rule, mencakup semua kombinasi BB × TB)

Rule	IF Z-BB/U	AND Z-TB/U	THEN Skor Risiko
R1	RENDAH	PENDEK	TINGGI

Rule	IF Z-BB/U	AND Z-TB/U	THEN Skor Risiko
R2	RENDAH	NORMAL	SEDANG
R3	RENDAH	TINGGI	SEDANG
R4	NORMAL	PENDEK	TINGGI
R5	NORMAL	NORMAL	RENDAH
R6	NORMAL	TINGGI	RENDAH
R7	TINGGI	PENDEK	SEDANG
R8	TINGGI	NORMAL	RENDAH
R9	TINGGI	TINGGI	RENDAH

Logika: tinggi badan pendek (stunting) adalah indikator utama, sehingga TB PENDEK dengan BB normal pun tetap TINGGI (R4).

(iii) Hitung manual — Balita B03 (Budi, 18 bln, BB 7,4 kg, TB 74 cm)

Langkah 1 — Z-Score

- Z-BB/U = (7,4 − 10,9) / 1,2 = **−2,917**
- Z-TB/U = (74 − 82,3) / 3,2 = **−2,594**

Keduanya < −2, jadi Budi memang berisiko kuat.

Langkah 2 — Fuzzifikasi

Z-BB = −2,917:

- RENDAH (turun, c=−3, d=−1): (−1 − (−2,917)) / 2 = **0,9583**
- NORMAL (naik, a=−3, b=0): (−2,917 + 3) / 3 = **0,0278**
- TINGGI = 0

Z-TB = −2,594:

- PENDEK: (−1 + 2,594) / 2 = **0,7969**
- NORMAL: (−2,594 + 3) / 3 = **0,1354**
- TINGGI = 0

Langkah 3 — Rule aktif dan alpha (AND = min)

Rule	Perhitungan	Alpha	Output
R1	min(0,9583; 0,7969)	**0,7969**	TINGGI
R2	min(0,9583; 0,1354)	**0,1354**	SEDANG
R4	min(0,0278; 0,7969)	**0,0278**	TINGGI
R5	min(0,0278; 0,1354)	**0,0278**	RENDAH

Rule	Perhitungan	Alpha	Output
R3, R6–R9	salah satu input = 0	0	tidak aktif

Langkah 4 — Agregasi (max per himpunan output)

- TINGGI = max(0,7969; 0,0278) = **0,7969**
- SEDANG = **0,1354**
- RENDAH = **0,0278**

Setiap himpunan output dipotong (alpha-cut) pada tinggi di atas, lalu digabung dengan max.

Langkah 5 — Defuzzifikasi centroid ($Z^* = \Sigma$ momen / Σ luas)

Daerah x	μ(x)	Luas	Titik berat	Momen
0 – 0,42	naik ke 0,0278	0,006	0,28	0,002
0,42 – 25,56	0,0278 (RENDAH)	0,698	12,99	9,068
25,56 – 27,71	naik 0,0278→0,1354	0,176	26,87	4,720
27,71 – 62,29	0,1354 (SEDANG)	4,683	45,00	210,752
62,29 – 62,50	turun 0,1354→0,125	0,027	62,40	1,690
62,50 – 75,94	naik 0,125→0,7969	6,194	70,85	438,823
75,94 – 84,06	0,7969 (TINGGI)	6,475	80,00	517,969
84,06 – 100	turun 0,7969→0	6,350	89,38	567,558
Total		**24,609**		**1750,58**

Skor Risiko = 1750,58 / 24,609 ≈ 71,1

Kesimpulan: skor ≈ 71 berada di himpunan TINGGI (60–100) → Budi **berisiko tinggi stunting**, sesuai label Dataset A (Stunting).

1b. Sistem Pakar (validasi klinis setelah FIS)

(i) Rule Base (9 rule)

Aturan diperiksa berurutan dari atas; rule pertama yang cocok dipakai (conflict resolution = urutan prioritas, kasus paling berat lebih dulu).

Rule	IF	THEN diagnosa	Rekomendasi
R1	z_TB < −2 AND z_BB < −2 AND LILA < 11,5	STUNTING (berat, disertai gizi kurang akut)	Rujuk segera ke Puskesmas/dokter anak, PMT pemulihan, cek penyakit penyerta

Rule	IF	THEN diagnosa	Rekomendasi
R2	z_TB < −2 AND skor_FIS ≥ 60	STUNTING	Rujuk Puskesmas, PMT, pemantauan intensif tiap 2 minggu
R3	z_TB < −2 AND skor_FIS < 60	STUNTING (ringan–sedang)	Konseling gizi, protein hewani pada MP-ASI, ukur ulang tiap bulan
R4	z_TB ≥ −2 AND z_BB < −2	GIZI KURANG	PMT, edukasi pola makan, timbang ulang 2 minggu
R5	z_TB ≥ −2 AND LILA < 11,5	GIZI KURANG	PMT, ukur ulang LILA, cek infeksi/cacingan
R6	z_TB ≥ −2 AND z_BB ≥ −2 AND LILA ≥ 11,5 AND 30 ≤ skor_FIS < 60 AND ASI = Tidak	GIZI KURANG (ringan/berisiko)	Konseling gizi ibu, perbaiki MP-ASI, timbang ulang 2 minggu
R7	z_TB ≥ −2 AND z_BB ≥ −2 AND LILA ≥ 11,5 AND skor_FIS < 30	NORMAL	Lanjutkan pemantauan rutin Posyandu tiap bulan
R8	z_TB ≥ −2 AND z_BB ≥ −2 AND LILA ≥ 11,5 AND 30 ≤ skor_FIS < 60 AND ASI = Ya	NORMAL (pantau)	Pertahankan pola makan, pantau 1–2 bulan
R9	z_TB ≥ −2 AND z_BB ≥ −2 AND LILA ≥ 11,5 AND skor_FIS ≥ 60	NORMAL (perlu validasi)	FIS dan ukuran tidak sinkron: ukur ulang BB/TB, cek input

Peran FIS: skor FIS dipakai sebagai kondisi tambahan sehingga sistem pakar benar-benar "memvalidasi" output FIS (R9 menangkap konflik/kesalahan ukur).

(ii) Forward Chaining — Balita B02 (Siti)

Pra-proses (turunan fakta): Siti perempuan 36 bln. Estimasi WHO: BB median 13,9 kg (SD 1,6); TB median 95,1 cm (SD 3,85).

- z_BB = (11,8 − 13,9)/1,6 = **−1,31**
- z_TB = (88 − 95,1)/3,85 = **−1,84**
- Skor FIS (dihitung dengan prosedur yang sama seperti B03; alpha: BB RENDAH 0,155, NORMAL 0,563; TB PENDEK 0,42, NORMAL 0,39) **≈ 51,7** (SEDANG)

Iterasi	Working Memory	Rule yang match	Rule yang fired	Fakta baru
Awal	umur=36, BB=11,8, TB=88,	—	—	—

Iterasi	Working Memory	Rule yang match	Rule yang fired	Fakta baru
	LILA=12,1, ASI=Tidak, z_BB=−1,31, z_TB=−1,84, skor_FIS=51,7			
1	WM awal	Hanya R6 (z_TB ≥ −2 ✓, z_BB ≥ −2 ✓, LILA ≥ 11,5 ✓, 30 ≤ 51,7 < 60 ✓, ASI=Tidak ✓). R1–R3 gagal (z_TB ≥ −2); R4 gagal (z_BB ≥ −2); R5 gagal (LILA ≥ 11,5); R7 gagal (skor ≥ 30); R8 gagal (ASI=Tidak); R9 gagal (skor < 60)	**R6**	diagnosa = GIZI KURANG (ringan/berisiko)
2	WM awal + diagnosa=GIZI KURANG	Tidak ada rule baru yang cocok	—	— → **berhenti**

Kesimpulan & rekomendasi: Siti terdiagnosis **GIZI KURANG (ringan/berisiko)** — sesuai label Dataset A. Rekomendasi: konseling gizi ibu, perbaiki MP-ASI (protein hewani), timbang ulang dalam 2 minggu. Perhatian: tinggi badan Siti (z = −1,84) hampir menyentuh batas stunting, sehingga perlu dipantau agar tidak turun di bawah −2.

1c. XGBoost vs Decision Tree vs FIS vs Sistem Pakar

Kode: memakai notebook `UTS_1c_2411002.ipynb` (dikumpulkan terpisah sebagai `UTS_Kode_NIM.ipynb`). Alur kode:

1. Baca Dataset B (200 baris: 124 Normal, 76 Risiko). Label "0 (Normal)"/"1 (Risiko)" diambil angka pertama; ASI Ya/Tidak → 1/0.
2. Fitur: Umur, BB, TB, LILA, ASI. Split 80:20, `stratify=y`, `random_state=42` → 160 data latih, 40 data uji (15 Risiko, 25 Normal).
3. Tuning XGBoost dengan **GridSearchCV** (cv=5, scoring=F1).
4. Baseline Decision Tree (`max_depth=4`). Evaluasi pada data uji.

(i) Tabel metrik (data uji, 40 sampel)

Model / Pendekatan	Accuracy	Precision	Recall	F1-Score	ROC-AUC
XGBoost (Tuned)	85,0%	90,9%	66,7%	76,9%	84,7%
Decision Tree (Baseline)	77,5%	87,5%	46,7%	60,9%	79,6%
FIS Mamdani (estimasi)	____%	____%	____%	____%	____%

Model / Pendekatan	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Sistem Pakar (estimasi)	____%	____%	____%	____%	____%

> *Isi baris FIS dan Sistem Pakar dari output Bagian 2 notebook Anda (evaluasi biner Normal vs Risiko pada data uji yang sama). FIS/Sistem Pakar tidak menghasilkan probabilitas, jadi ROC-AUC FIS bisa dihitung dari skor 0–100, sedangkan Sistem Pakar cukup diisi "—" atau dihitung dari prediksi biner.*

Pembacaan confusion matrix dari metrik: XGBoost TP=10, FP=1, FN=5, TN=24; Decision Tree TP=7, FP=1, FN=8, TN=24.

(ii) Hyperparameter XGBoost

Parameter	Nilai Dicoba	Nilai Terbaik	Metode Tuning
n_estimators	50, 100	**100**	GridSearchCV (5-fold, scoring F1)
learning_rate	0,03; 0,1	**0,1**	GridSearchCV
max_depth	1, 2, 3	**2**	GridSearchCV
subsample	0,8; 1,0	**1,0**	GridSearchCV
colsample_bytree (parameter ke-5)	0,8; 1,0	**1,0**	GridSearchCV

Total kombinasi 2×2×3×2×2 = 48, dengan 5-fold → 240 kali pelatihan. Hasil terbaik berupa pohon dangkal (depth 2) dan learning rate lebih besar, yang wajar untuk data kecil (160 baris) agar tidak overfitting.

(iii) Analisis perbandingan

1. Paling akurat. Dari model yang terukur, XGBoost (tuned) unggul atas Decision Tree di semua metrik: akurasi 85,0% vs 77,5%, F1 76,9% vs 60,9%, AUC 84,7% vs 79,6%. Peningkatan terbesar ada di recall (66,7% vs 46,7%): ensemble boosting menggabungkan banyak pohon dangkal sehingga lebih banyak kasus risiko tertangkap. Untuk FIS dan Sistem Pakar, bandingkan angka pada baris tabel di atas dengan XGBoost. Catatan metodologis: data uji hanya 40 sampel, satu kasus salah tebak mengubah recall ±6,7 poin, sehingga selisih kecil antar model perlu dibaca hati-hati.

2. Paling mudah dijelaskan ke dokter. Sistem Pakar, karena setiap keputusan berasal dari aturan eksplisit yang sejalan dengan standar antropometri (misalnya z-TB < −2 = stunting) dan disertai kolom alasan. FIS berada di tengah: aturannya linguistik ("BB rendah DAN TB pendek → risiko tinggi") sehingga masih mudah dipahami, tetapi skor akhir hasil centroid tidak mudah dihitung di kepala. XGBoost paling sulit dijelaskan (ratusan pohon), meski bisa dibantu feature importance/SHAP.

3. Pilihan untuk Puskesmas. Rekomendasi: **Sistem Pakar sebagai keputusan utama**, dengan XGBoost sebagai pendukung skrining. Alasan: (a) keputusan klinis harus bisa dipertanggungjawabkan dan sesuai standar Kemenkes/WHO; (b) tidak butuh data pelatihan besar atau pelatihan ulang; (c) mudah diaudit dan diubah jika pedoman berubah. Kekurangan

XGBoost pada hasil ini adalah recall 66,7%: 5 dari 15 balita berisiko lolos, berbahaya untuk skrining. Jika hanya boleh satu, pilih Sistem Pakar; bila ingin sensitivitas lebih tinggi, turunkan threshold probabilitas XGBoost atau gunakan `scale_pos_weight`.

SOAL 2 — Tracing Manual Forward & Backward Chaining

Fakta awal Hana: berat_badan_kurang=YA, usia_di_bawah_24_bulan=YA, asi_eksklusif_tidak=YA, tinggi_badan_pendek=TIDAK, orang_tua_menolak=TIDAK.

2a. Forward Chaining

Iter.	Working Memory (WM)	Rule yang Match	Rule yang Fired	Fakta Baru ke WM
Awal	BBK=YA, U24=YA, ASI_tidak=YA, TBP=TIDAK, OTM=TIDAK	—	—	—
1	WM awal	**R1** (BBK=YA ∧ U24=YA ✓). R2 ✗ (risiko_stunting_dini belum ada); R3 ✗ (TBP=TIDAK); R4 ✗; R5 ✗	R1	risiko_stunting_dini=YA
2	WM awal + risiko_stunting_dini=YA	**R2** (risiko=YA ∧ ASI_tidak=YA ✓). R3 ✗; R4 ✗; R5 ✗	R2	stunting_berpotensi_parah=YA
3	WM + stunting_berpotensi_parah=YA	**R4** (gizi_buruk=YA OR stunting_berpotensi_parah=YA ✓ via bagian kedua). R3 ✗; R5 ✗ (rujuk belum ada)	R4	rujuk_puskesmas=YA
4	WM + rujuk_puskesmas=YA	**R5** (rujuk=YA ∧ OTM=TIDAK ✓). R3 ✗	R5	jadwalkan_pemantauan_intensif=YA
5	WM lengkap	R3 ✗ (TBP=TIDAK); tidak ada rule lain	—	— → **berhenti**

Kesimpulan akhir: Hana berisiko stunting dini yang berpotensi parah → **dirujuk ke Puskesmas** dan **dijadwalkan pemantauan intensif**. Fakta `gizi_buruk` tidak terbukti (R3 tidak pernah terpenuhi karena tinggi badan Hana normal).

2b. Backward Chaining

(i) Pohon pembuktian

```
GOAL: jadwalkan_pemantauan_intensif = YA
└─ Rule pendukung: R5 (rujuk_puskesmas=YA AND orang_tua_menolak=TIDAK)
   ├─ Sub-goal 1: rujuk_puskesmas = YA
   │  └─ Rule pendukung: R4 (gizi_buruk=YA OR stunting_berpotensi_parah=YA)
   │     ├─ Cabang A: gizi_buruk = YA
   │     │  └─ Rule: R3 (tinggi_badan_pendek=YA AND berat_badan_kurang=YA)
   │     │     ├─ tinggi_badan_pendek = YA ? → fakta WM: TIDAK  ✗ GAGAL
   │     │     └─ (berat_badan_kurang tidak perlu dicek). Tidak ada rule lain → cabang A GAGAL
   │     └─ Cabang B: stunting_berpotensi_parah = YA   (karena OR, cukup salah satu)
   │        └─ Rule: R2 (risiko_stunting_dini=YA AND asi_eksklusif_tidak=YA)
   │           ├─ Sub-goal: risiko_stunting_dini = YA
   │           │  └─ Rule: R1 (berat_badan_kurang=YA AND usia_di_bawah_24_bulan=YA)
   │           │     ├─ berat_badan_kurang = YA  → fakta WM ✓
   │           │     └─ usia_di_bawah_24_bulan = YA → fakta WM ✓  ⇒ R1 TERBUKTI
   │           └─ asi_eksklusif_tidak = YA → fakta WM ✓  ⇒ R2 TERBUKTI
   │        ⇒ stunting_berpotensi_parah = YA ⇒ R4 TERBUKTI (OR)
   │     ⇒ rujuk_puskesmas = YA ✓
   └─ Sub-goal 2: orang_tua_menolak = TIDAK → fakta WM ✓
⇒ R5 TERBUKTI ⇒ GOAL TERBUKTI: jadwalkan_pemantauan_intensif = YA
```

Tidak perlu bertanya ke user karena semua fakta dasar sudah ada di working memory.

(ii) Perbandingan FC vs BC

Keduanya mencapai kesimpulan yang **sama**: `jadwalkan_pemantauan_intensif = YA`.

Aspek	Forward Chaining	Backward Chaining
Arah	Dari fakta → kesimpulan (data-driven)	Dari goal → fakta pendukung (goal-driven)
Rule yang dijalankan/dibuktikan	4 rule fired (R1, R2, R4, R5)	4 rule terbukti (R5, R4, R2, R1) + 1 rule gagal dicoba (R3)
Jumlah evaluasi rule	15 pemeriksaan (5+4+3+2+1) dalam 5 iterasi	5 rule dikunjungi (R5, R4, R3, R2, R1), sekitar 6 pengecekan fakta
Fakta turunan	Menghasilkan semua fakta turunan	Hanya yang dibutuhkan untuk goal

Analisis: pada kasus Hana, BC lebih hemat karena hanya menelusuri rule yang relevan terhadap goal dan tidak mengulang pemeriksaan seluruh rule di tiap iterasi. Satu-satunya langkah "boros" BC adalah mencoba cabang gizi_buruk (R3) lebih dulu dan gagal; jika cabang stunting_berpotensi_parah diurutkan lebih dulu, BC langsung berhasil tanpa backtrack. FC tidak sia-sia di sini karena semua fakta turunannya (risiko dini, berpotensi parah, rujukan) memang ikut dibutuhkan dan berguna untuk laporan lengkap. Secara umum: FC cocok saat ingin menemukan semua kesimpulan dari data yang ada (monitoring), BC cocok saat hanya ingin membuktikan satu hipotesis.

SOAL 3 — Essay: Kapan Memilih Sistem Pakar dibanding XGBoost?

Aspek A — Kondisi yang cocok untuk Sistem Pakar

1. **Data latih sedikit atau tidak tersedia.** Sistem pakar bekerja dari pengetahuan pakar dan pedoman tertulis, bukan dari data historis. Pada domain baru atau jarang (penyakit langka, kebijakan baru), XGBoost tidak punya cukup contoh untuk belajar. Contoh: pedoman klinis baru yang belum punya data pasien.
2. **Interpretabilitas dan akuntabilitas wajib.** Di bidang medis, hukum, dan pemerintahan, keputusan harus bisa dijelaskan langkah demi langkah ("karena z-TB < −2 maka stunting"). Rule dapat ditelusuri dengan forward/backward chaining dan diaudit.
3. **Pengetahuan sudah terkodifikasi dan stabil.** Jika ada standar atau regulasi (misalnya standar antropometri Kemenkes), aturan bisa langsung ditulis dan diubah cepat saat standar berubah tanpa pelatihan ulang.
4. **Biaya kesalahan tinggi dan perlu perilaku deterministik.** Sistem pakar menghasilkan output yang sama untuk input yang sama dan tidak "halusinasi" pada data aneh di luar distribusi latih.

Aspek B — Kondisi yang cocok untuk XGBoost

1. **Data besar, tabular, dan berlabel.** XGBoost (Chen & Guestrin, 2016) sangat kuat pada data tabular dengan ribuan hingga jutaan baris.
2. **Pola kompleks dan nonlinier yang sulit dirumuskan manusia.** Interaksi antar puluhan fitur (misalnya skor kredit dari ratusan atribut) dapat dipelajari otomatis tanpa pakar menulis aturan satu per satu.
3. **Prioritas pada akurasi prediktif dan pengetahuan pakar tidak lengkap.** Model dapat menemukan faktor tersembunyi dan beradaptasi saat data baru masuk lewat pelatihan ulang; ada fitur bawaan untuk missing value dan regularisasi.
4. **Sistem harus diskalakan otomatis.** Pelatihan dan inferensi cepat, cocok untuk prediksi jutaan transaksi (deteksi fraud, prediksi churn).

Aspek C — Kasus nyata Indonesia: Skrining status gizi balita di Posyandu

(1) Deskripsi masalah. Kader Posyandu dan bidan desa menentukan status gizi balita (normal, gizi kurang, stunting) dari umur, BB, dan TB, memakai Standar Antropometri Anak dari Permenkes No. 2 Tahun 2020 (Kementerian Kesehatan RI, 2020). Hasilnya menentukan apakah anak diberi PMT, dikonseling, atau dirujuk ke Puskesmas.

(2) Mengapa Sistem Pakar lebih tepat. Kriteria diagnosis sudah baku (ambang z-score) sehingga aturan dapat ditulis langsung. Tenaga kesehatan dan kader dengan pelatihan terbatas perlu penjelasan yang jelas dan mudah dipercaya orang tua ("anak Ibu dirujuk karena tinggi badannya di bawah −2 SD"). Sistem juga dapat memberi rekomendasi tindakan per rule. Jika standar diperbarui, cukup ubah rule. Sistem berjalan di perangkat sederhana tanpa pelatihan ulang, penting bagi daerah dengan infrastruktur terbatas.

(3) Kelemahan bila XGBoost dipaksakan. (a) Data berlabel sering sedikit dan bias (dan sebagian label sendiri berasal dari rumus z-score yang sama, sehingga model hanya mempelajari ulang aturan). Pada percobaan kami dengan 200 data, XGBoost hanya mencapai recall 66,7%, artinya 5 dari 15 balita berisiko terlewat, padahal rujukan terlambat berdampak permanen pada pertumbuhan anak. (b) Keputusan bersifat "kotak hitam", sulit dijelaskan ke ibu

dan bidan. (c) Perlu pemeliharaan model (pelatihan ulang, monitoring drift) yang belum tentu bisa dilakukan Puskesmas. (d) Model dapat memberi hasil tidak konsisten dengan standar resmi, sehingga sulit dipertanggungjawabkan secara regulasi.

Aspek D — Integrasi Sistem Pakar + XGBoost

Penggabungan sangat mungkin dan sering lebih baik (pendekatan hibrida). Skenario konkret **"Skrining Stunting Dua Tahap"** di Puskesmas:

1. **Tahap 1 — XGBoost sebagai penyaring risiko.** Model dilatih dari data historis seluruh Posyandu di kabupaten (umur, BB, TB, LILA, ASI eksklusif, berat lahir, sanitasi, pendapatan keluarga, riwayat infeksi). Outputnya adalah **probabilitas risiko stunting** (0–1) untuk tiap anak, termasuk anak yang antropometrinya masih "normal" tetapi faktor risikonya tinggi.
2. **Tahap 2 — Sistem Pakar sebagai validator klinis.** Probabilitas XGBoost menjadi **input/fakta baru** di working memory: misalnya prob_risiko = 0,82. Rule contoh: *IF prob_risiko ≥ 0,7 AND z_TB ≥ −2 THEN status = "WASPADA" → jadwalkan kunjungan ulang 2 minggu dan konseling gizi*; *IF prob_risiko ≥ 0,7 AND z_TB < −2 THEN diagnosa = STUNTING → rujuk Puskesmas*.
3. **Umpan balik.** Hasil diagnosis akhir dan outcome tindak lanjut disimpan sebagai label baru untuk melatih ulang XGBoost secara berkala. Sebaliknya, skor FIS/rule dapat juga dijadikan fitur masukan XGBoost.

Hasilnya: akurasi dan sensitivitas XGBoost digabung dengan transparansi dan kepatuhan standar dari sistem pakar; keputusan akhir tetap bisa dijelaskan ke dokter.

Daftar Referensi

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. https://doi.org/10.1145/2939672.2939785

Giarratano, J. C., & Riley, G. D. (2005). *Expert systems: Principles and programming* (4th ed.). Thomson Course Technology. https://libcat.library.tamu.edu/Record/in00002049608

Kementerian Kesehatan Republik Indonesia. (2020). *Peraturan Menteri Kesehatan Republik Indonesia Nomor 2 Tahun 2020 tentang Standar Antropometri Anak*. Kementerian Kesehatan RI. https://www.peraturan.go.id/files/bn7-2020.pdf

Russell, S., & Norvig, P. (2021). *Artificial intelligence: A modern approach* (4th ed.). Pearson. https://www.pearson.com/en-us/subject-catalog/p/artificial-intelligence-a-modern-approach/P200000003500